SBB CFF FFS

Von neuen Data Products und Knacknüssen

Dr. André Rogger

Bern, 08. März 2024

SBB facts & figures

- 35’000 employees, 5 business divisions
- 1.5 mio passengers, 5.800 train/day, 3.200 km tracks
- IT departement
  - SAFe as organisation model
  - 1’300/ 500 FTE intern/ ext employees.
  - > 2’500 business applications, thousands of OT applications
  - 120 enterprise architects
  - 100 data managers (business)
- Over 100 Data Products, and increasing
- Data Glossary Terms:
  - 20 top level concepts
  - > 200 high level terms
  - > 900 business data types

Stand: Februar 2024

Wo wir herkommen …

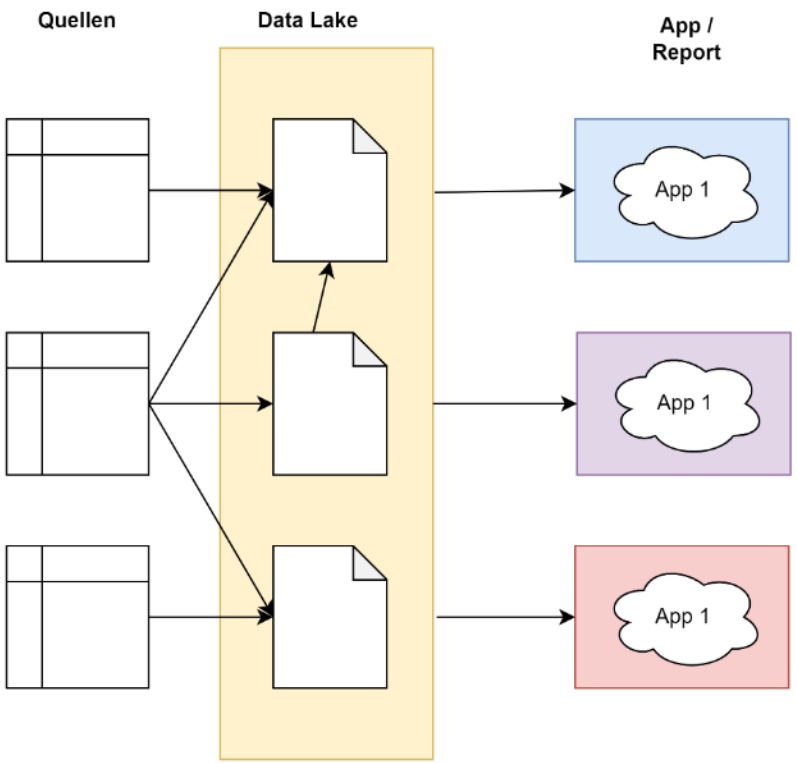

Sprengung. Bild: Giulio Casti, Italien, Sony World Photography Awards 2022, Daily Mail, 15. März 2022

C2 – Internal

… und wo die Reise hingeht

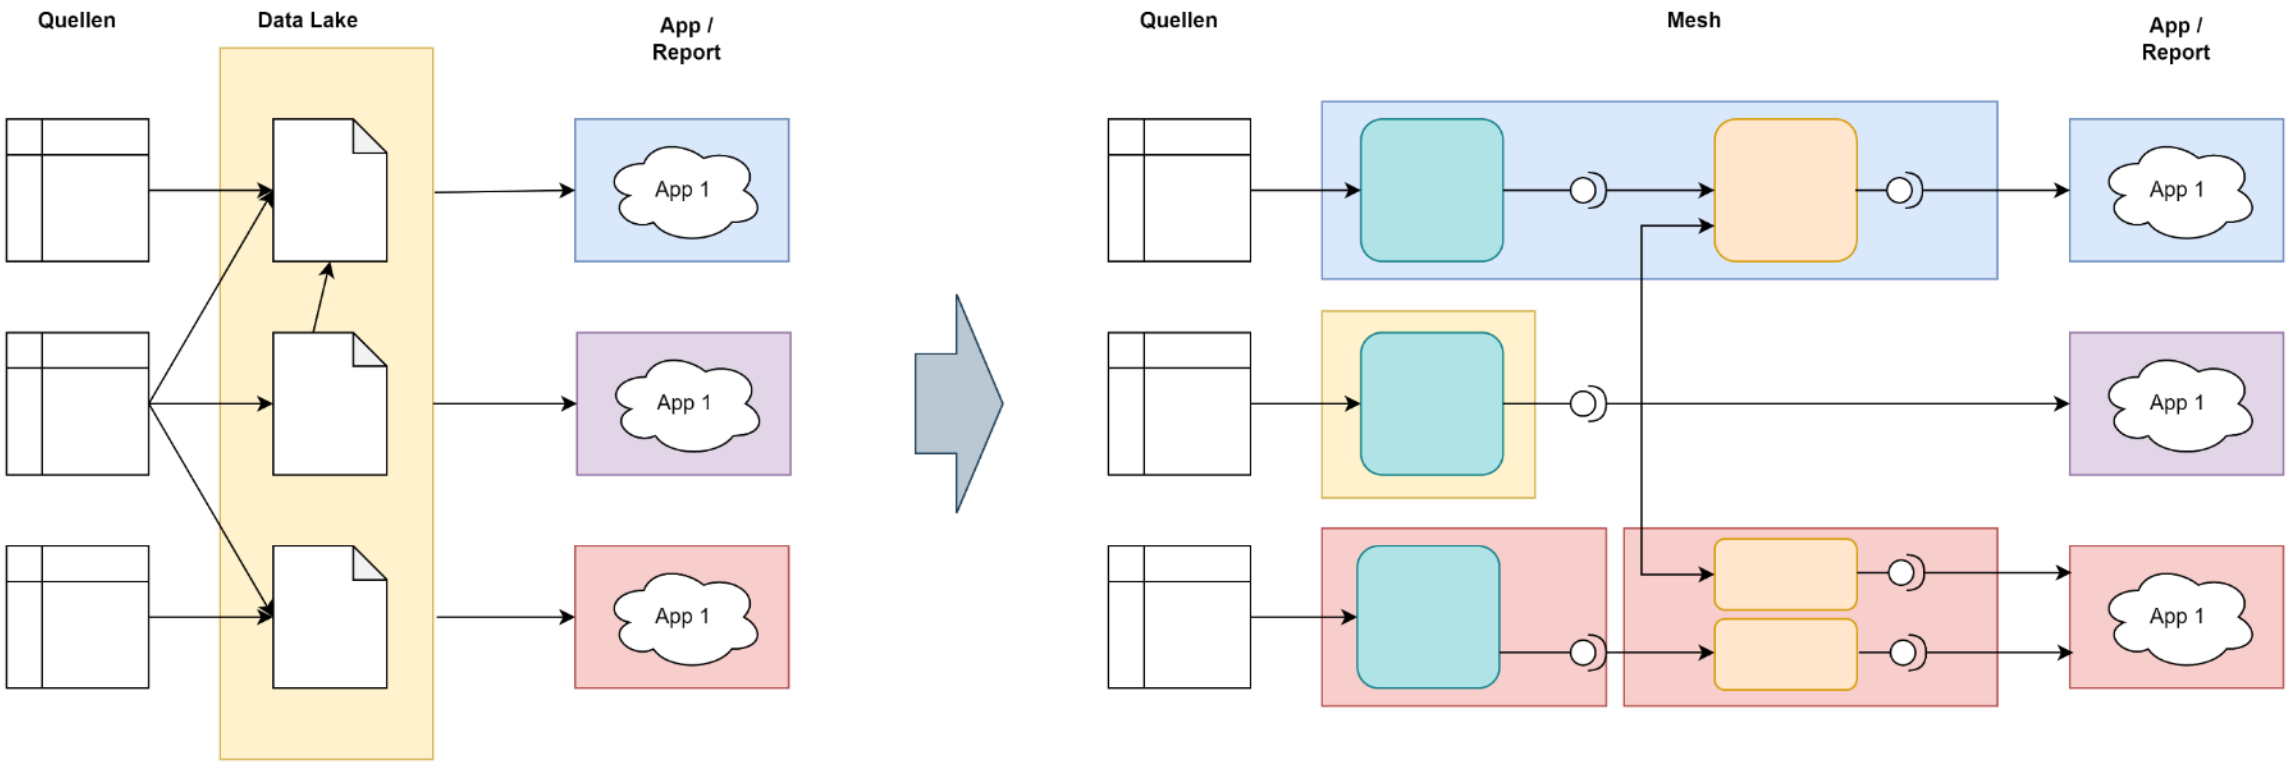

C2 – Internal

Was ist ein Data Product?
(noch eine Definition)

Ein Data Product ist eine Menge von wertorientierten «Data Assets», die speziell dazu erstellt und gemanaged werden, um schnell und sicher genutzt zu werden und das bei hoher Qualität, Verfügbarkeit und Einhaltung von Vorschriften und internen Richtlinien.

Als Analogie kann im SW-Devlopement ein Microservice dienen

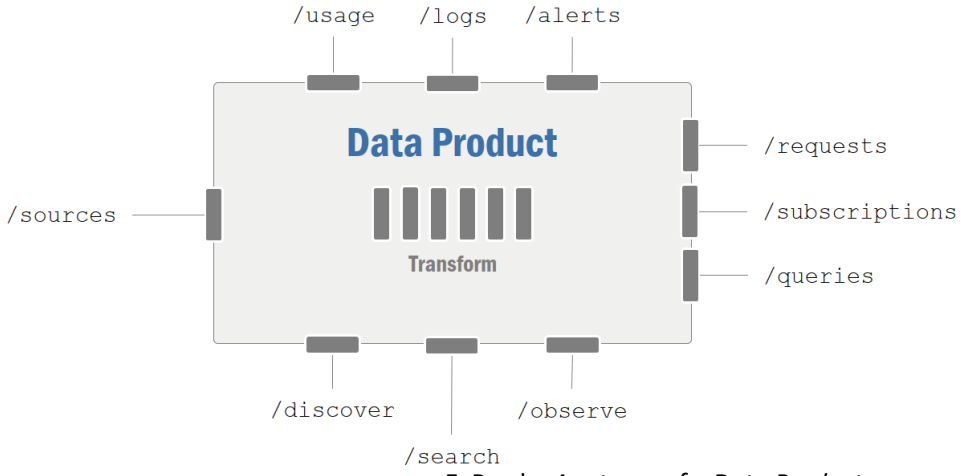

E. Broda, *Anatomy of a Data Product*. Broda Group Software, 2022. S. 5

C2 – Internal

Data Product seit Anfang 2022 Teil der SBB-Architekturprinzipien

Aus unserem «Daten- und Integrationsprinzip» (DIP)

«Wir stellen die Daten unserer Geschäftsfähigkeiten bedarfsorientiert als Datenprodukt in der Analytical Data Platform bereit. Für den Bezug von Daten aus den Datenprodukten über die Grenze der Analytical Data Platform hinaus stellen wir Schnittstellen bereit»

C2 – Internal

Weshalb Data Products

Durch Data Products sollen

- «analytische Daten» *schneller* genutzt werden können,
- *auffindbar* und *zugänglich* (DIP) werden,
- *Verantwortlichkeiten* geklärt und dadurch die *Datenqualität* sichergestellt,
- doppelte Datenimporte durch *Transparenz* verhindert werden und
- *Nutzung* der Daten überprüfbar gemacht werden.

Erlaubt eine konsistente Integration in die Konzepte der Domänen der SBB (Digital Solutions DSO)

C2 – Internal

Kompass für die Federated (computational) Governance

Governance by Transparenz:

- Dimensionen: Business Criticality, Datenschutz, Quality, …
- Notwendige Transparenz garantieren durch:
  - Was wird angeboten
  - Wer nutzt das Angebot
- Standardisierung im Schnittstellenbereich ohne Beeinträchtigung innerhalb der Datenprodukte

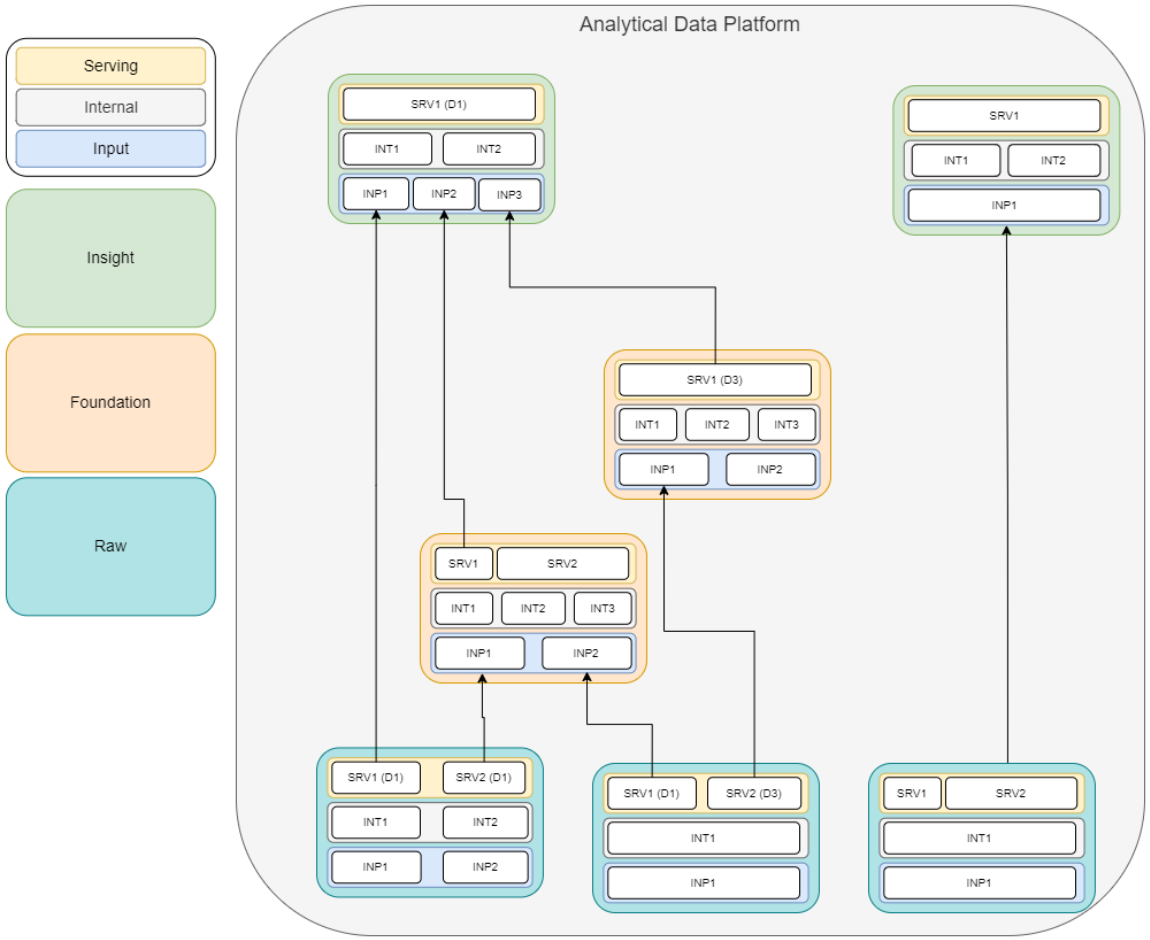

C2 – Internal

Typen von «Data Products» bei uns

- *Raw Data Products*
  (*source-aligned domain data*)
  Daten aus Quellsystemen und wenn sinnvoll als Produkt angeboten.
  Domänenspezifische einfache Standardisierungen möglich.
- *Foundation Data Products*
  (aggregate domain data)
  die «wirklichen» Data Products, mit Mehrwert für Datennutzer
- *Insight Data Products*
  (*consumer-aligned domain data*)
  vereinfachte Datenprodukte, die direkt zur Entscheidungsunterstützung verwendet werden (z.B. für Reports/Grafiken) oder aber die zu explorativen Zwecken genutzt werden sollen. werden nicht von anderen Datenprodukten verwendet.

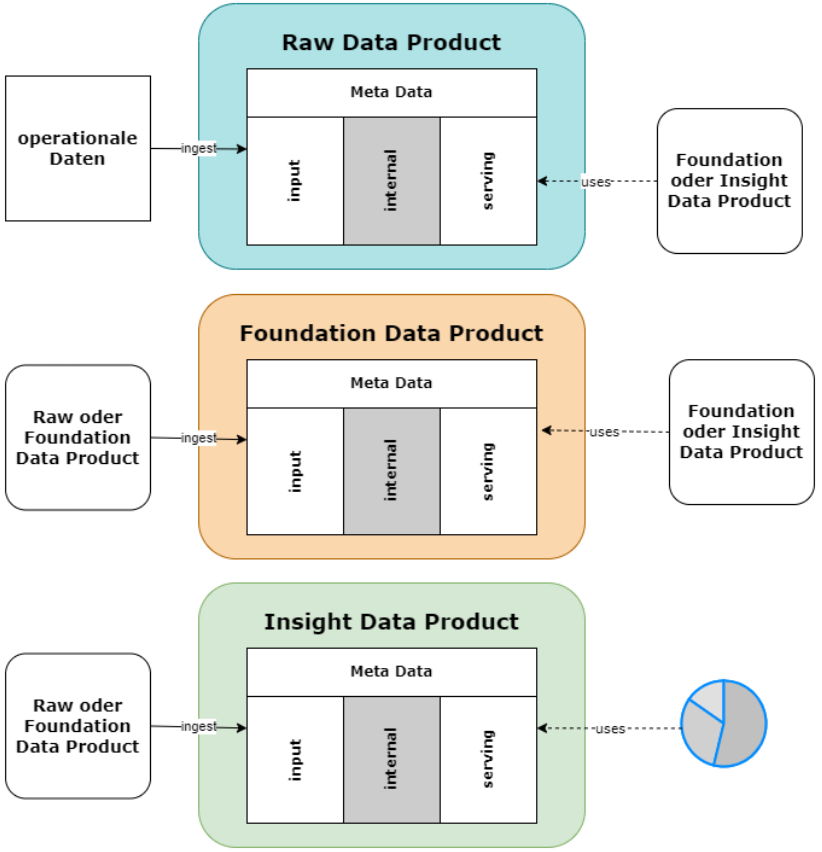

C2 – Internal

Do’s and Don’ts of Data Mesh
Insight von Kimeret Kimhi, BlaBlaCar

Quelle: freepik.com

Data Governance comes first

“[…] Your Data Governance Framework should be ideally set in place before re-organising. Why? Imagine giving a single team full autonomy with zero standards nor processes. You'll find yourself cleaning up a huge and expensive mess, one year down the line. […]”

K. Kimhi, ‘Do’s and Don’ts of Data Mesh’, *BlaBlaCar*, Sep. 06, 2022. https://medium.com/blablacar/dos-and-don-ts-of-data-mesh-e093f1662c2d (accessed Sep. 23).

C2 – Internal

Minimale Governace: Beispiel der aktuellen Designregeln

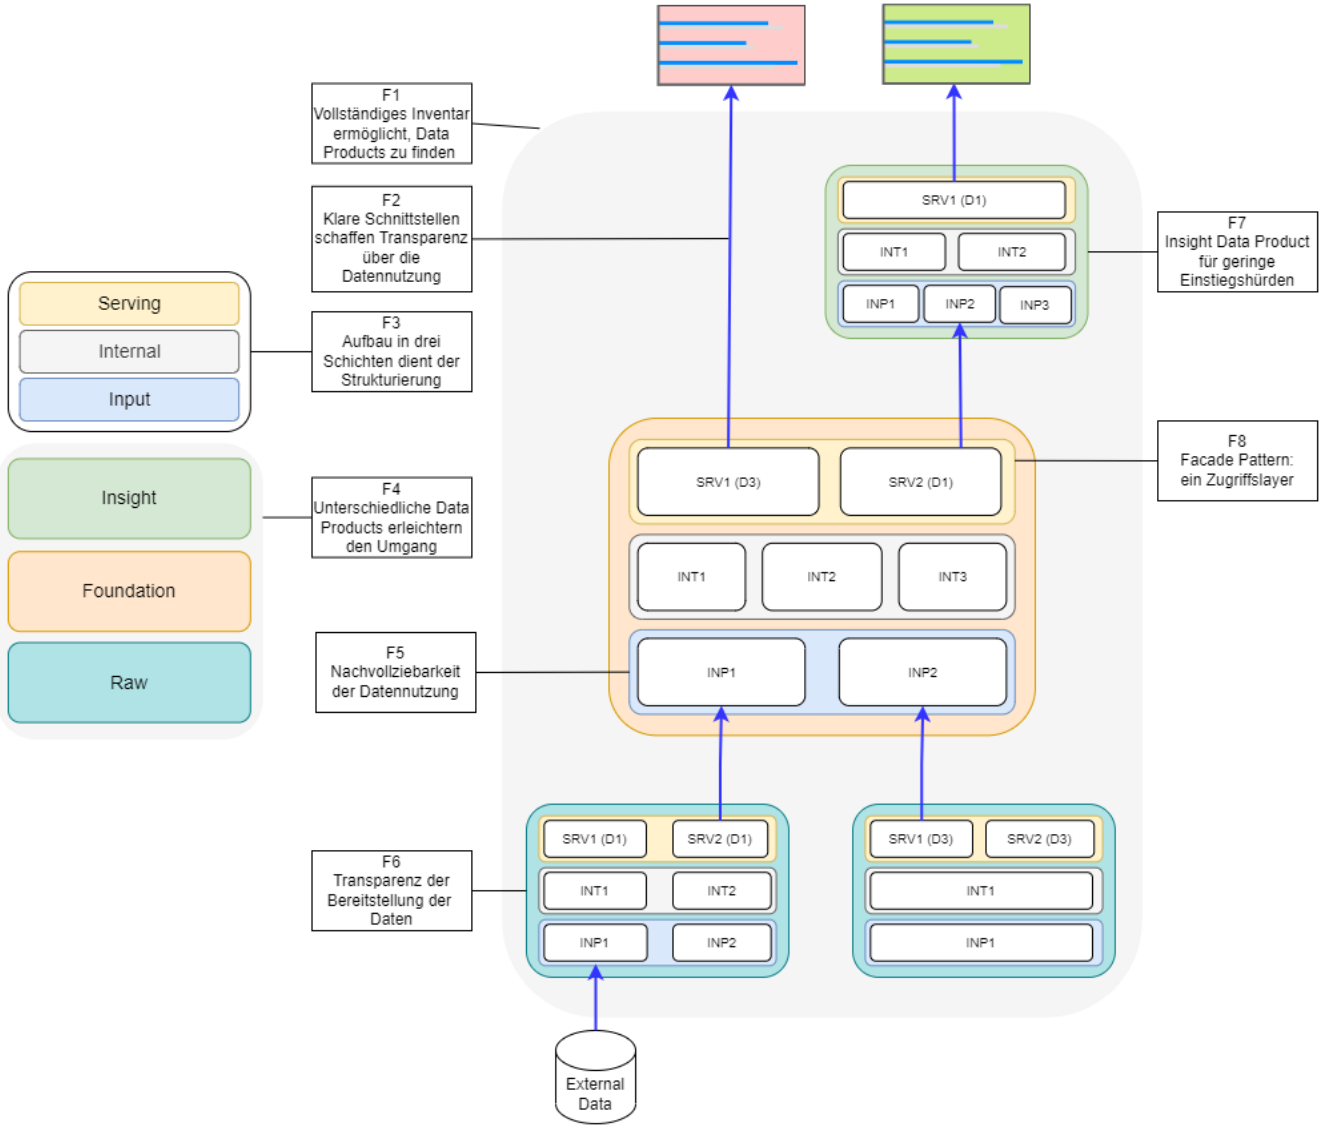

Dies sind einige der speziellen Regeln für Data Products.

Natürlich gelten alle Regeln der allgemeinen Data Governance wie Datenschutz, etc. hier implizit auch.

Generell verfolgt die SBB ein «Offenheitsprinzip», das heisst, Daten sind intern von allen zugänglich, ausser es handelt sich um als vertraulich eingestufte Inhalte.

C2 – Internal

Toolunterstützung

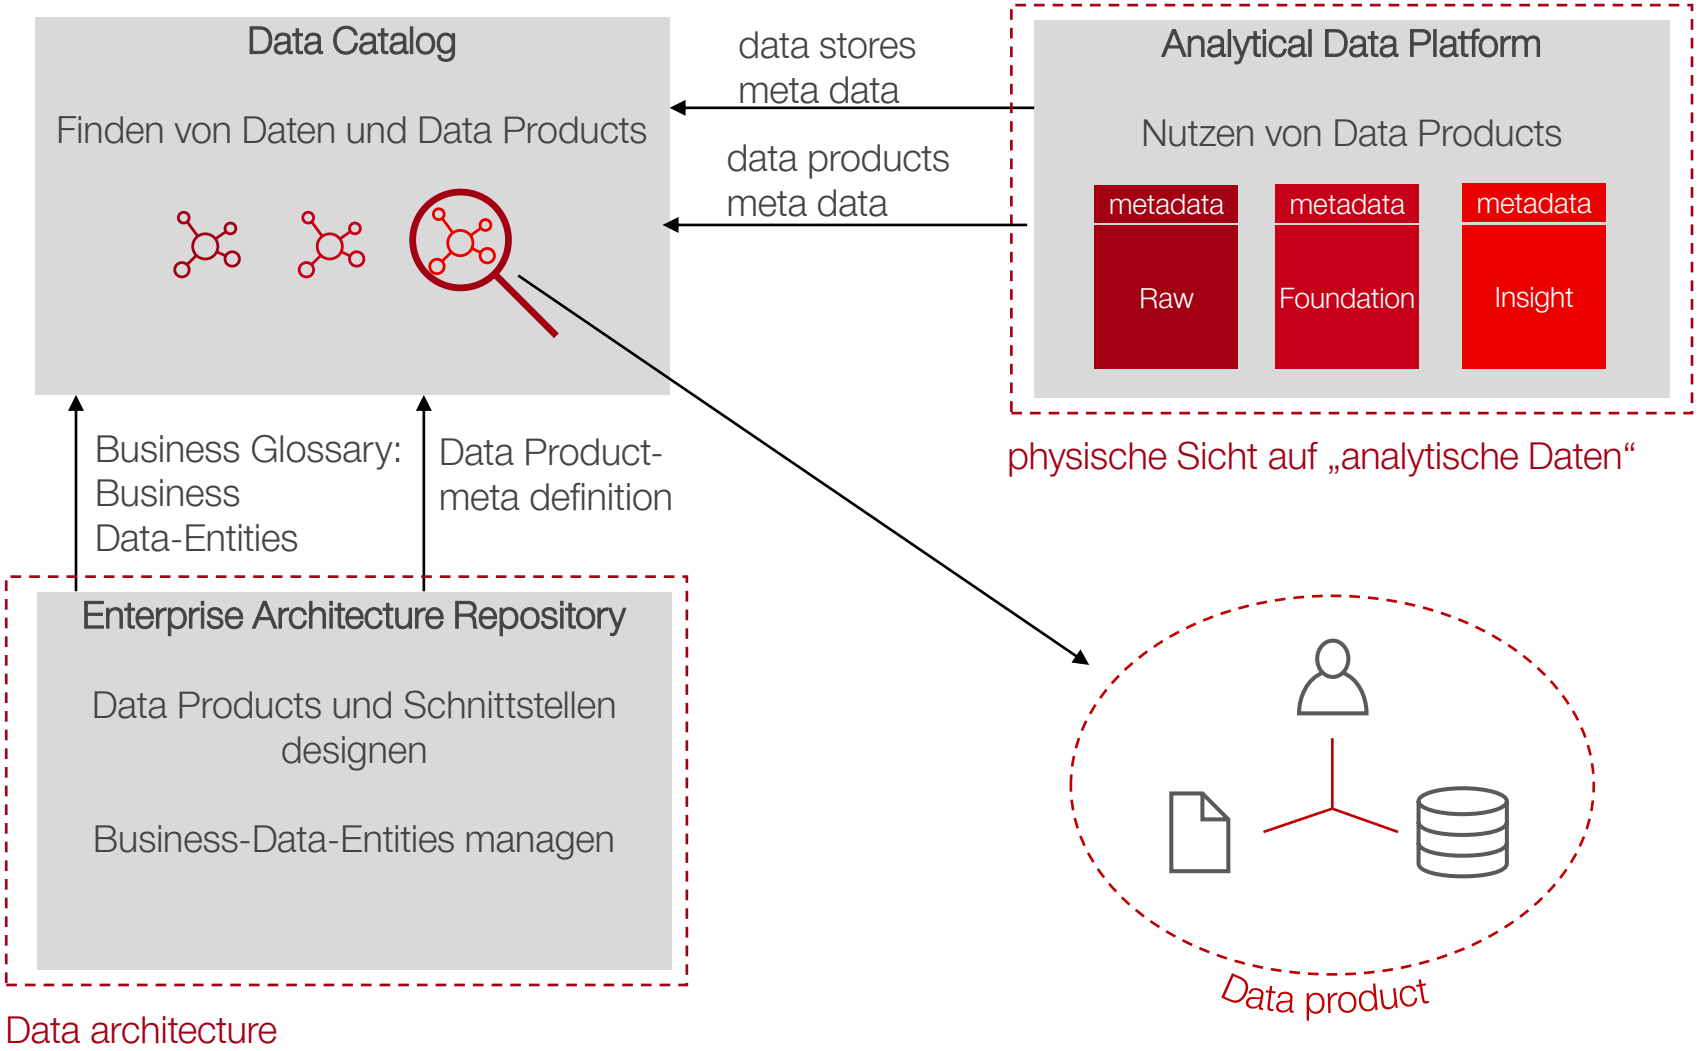

Der Data Catalog verbindet physische und fachliche Perspektiven und hält Benutzer und Verantwortliche

Ein neues Data Product erstellen

Data Product Bedarf feststellen

was

- Data Catalog konsultieren
- Bedarf für Anpassung von DP feststellen oder neues DP erstellen

Verantwortung

analytischer Bedarfsträger

- Data Scientist
- Data Analyst
- Business Analyst
- ...

planen

was

- DP Epic/Features erstellen
- Curator identifizieren

Verantwortung

System Architect

entwerfen

was

- DP im Enterprise Architecture Repository erstellen

Verantwortung

Curator

- Data Product Owner
- Business Process Owner
- Data Steward (FDM)
- ...

umsetzen

was

- DP in Analytical Data Platform bestellen
- DP in Analytical Data Platform integrieren/ implementieren

Verantwortung

System Architect

dokumentieren

was

- DP im Data Catalog fachlich anreichern
- DP mit Business Data Entities (Glossary) verknüpfen
- DP mit Data Sets verknüpfen

Verantwortung

Curator

- Rolle im Fach
- Rolle in DSO

C2 – Internal

Beispiel eines Raw Data Products im Enterprise Architecture Repository

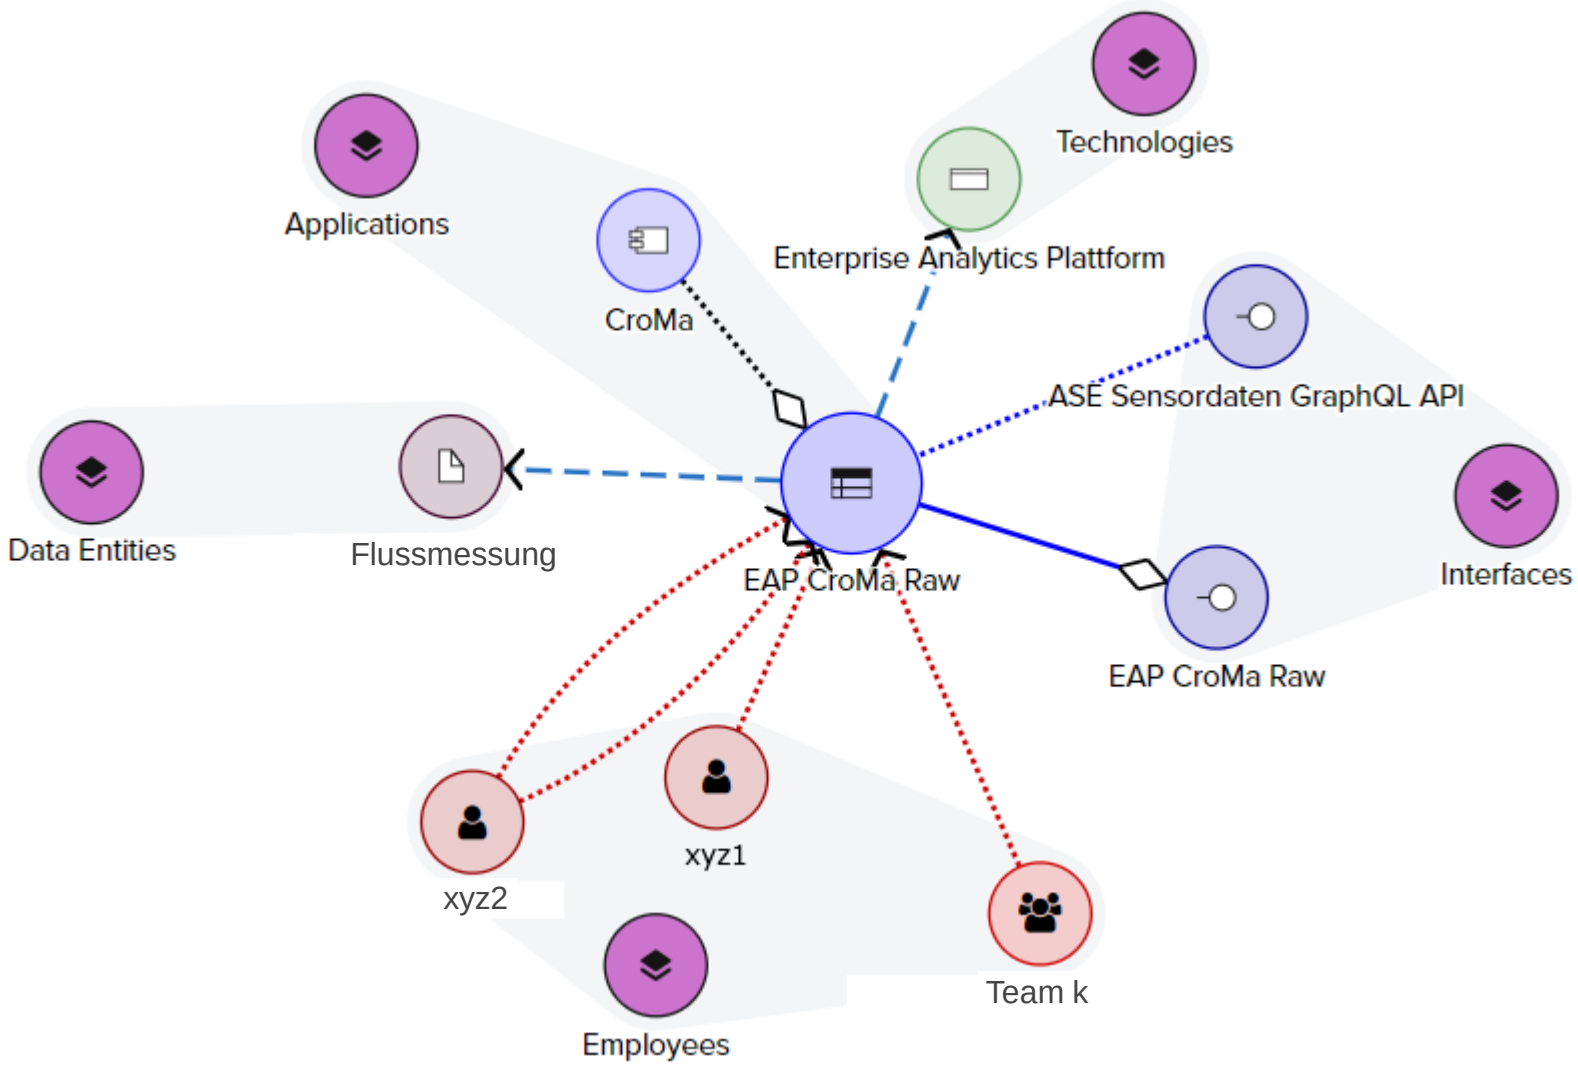

C2 – Internal

Sicht des Data Products im Data Catalog

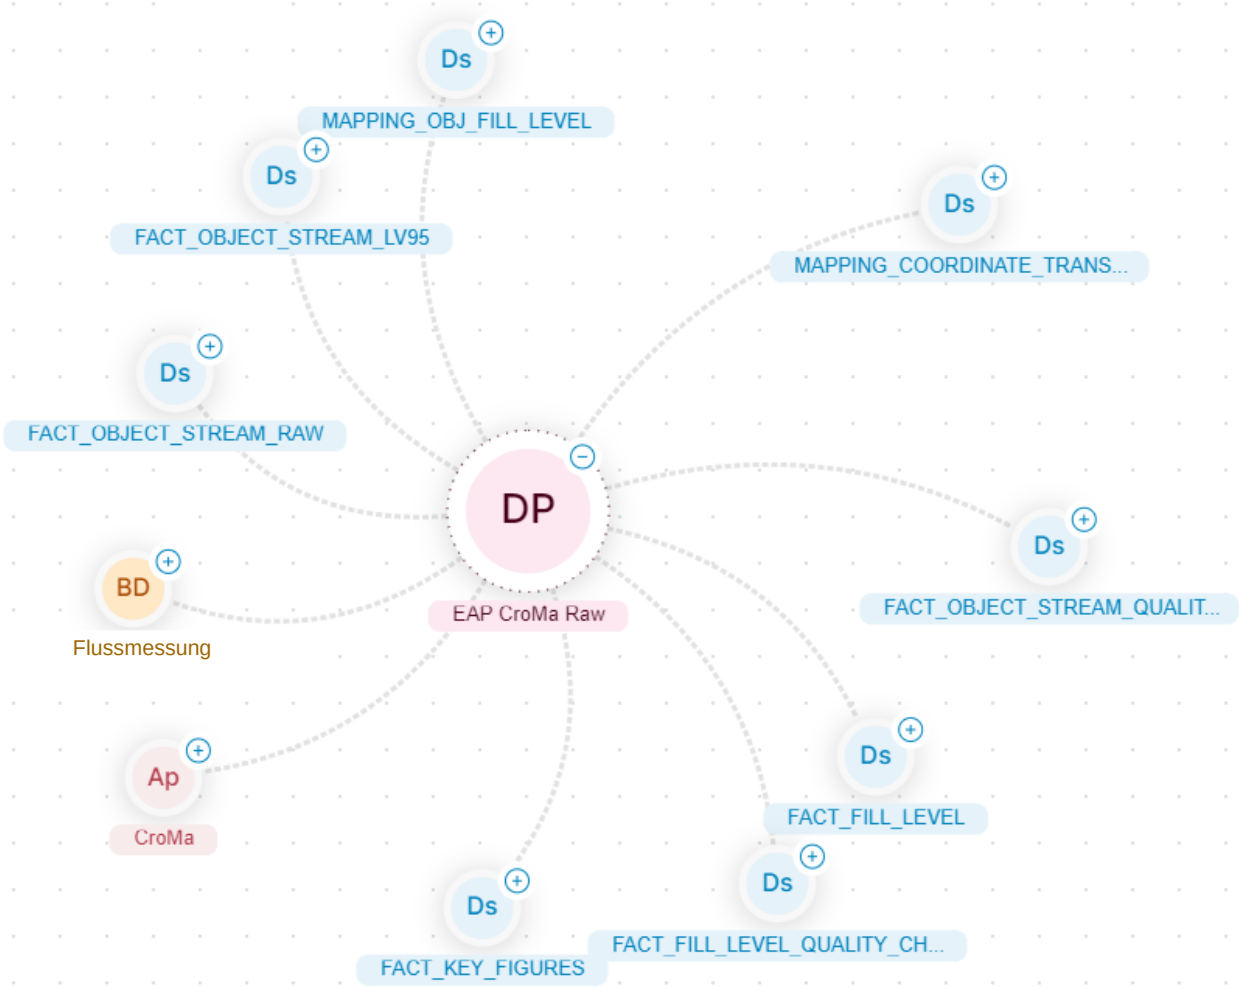

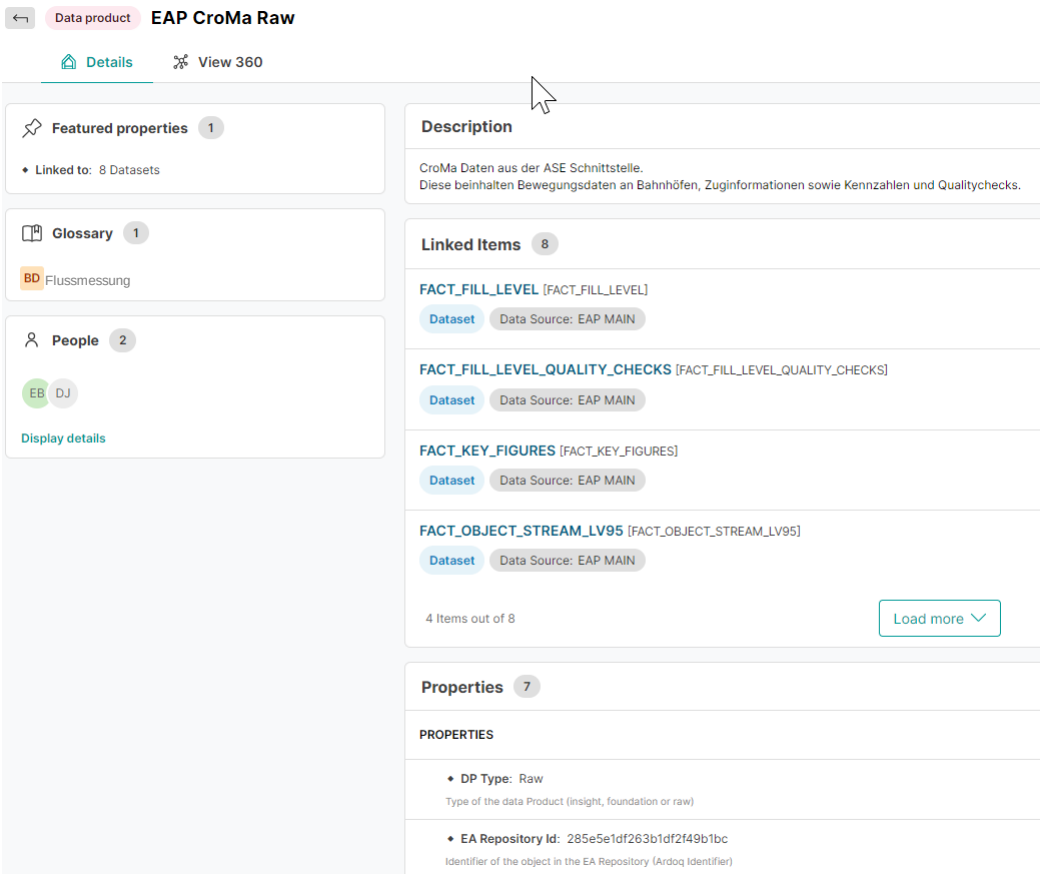

C2 – Internal

Zusammenspiel der einzelnen Parteien anhand der Data Mesh Pfeiler

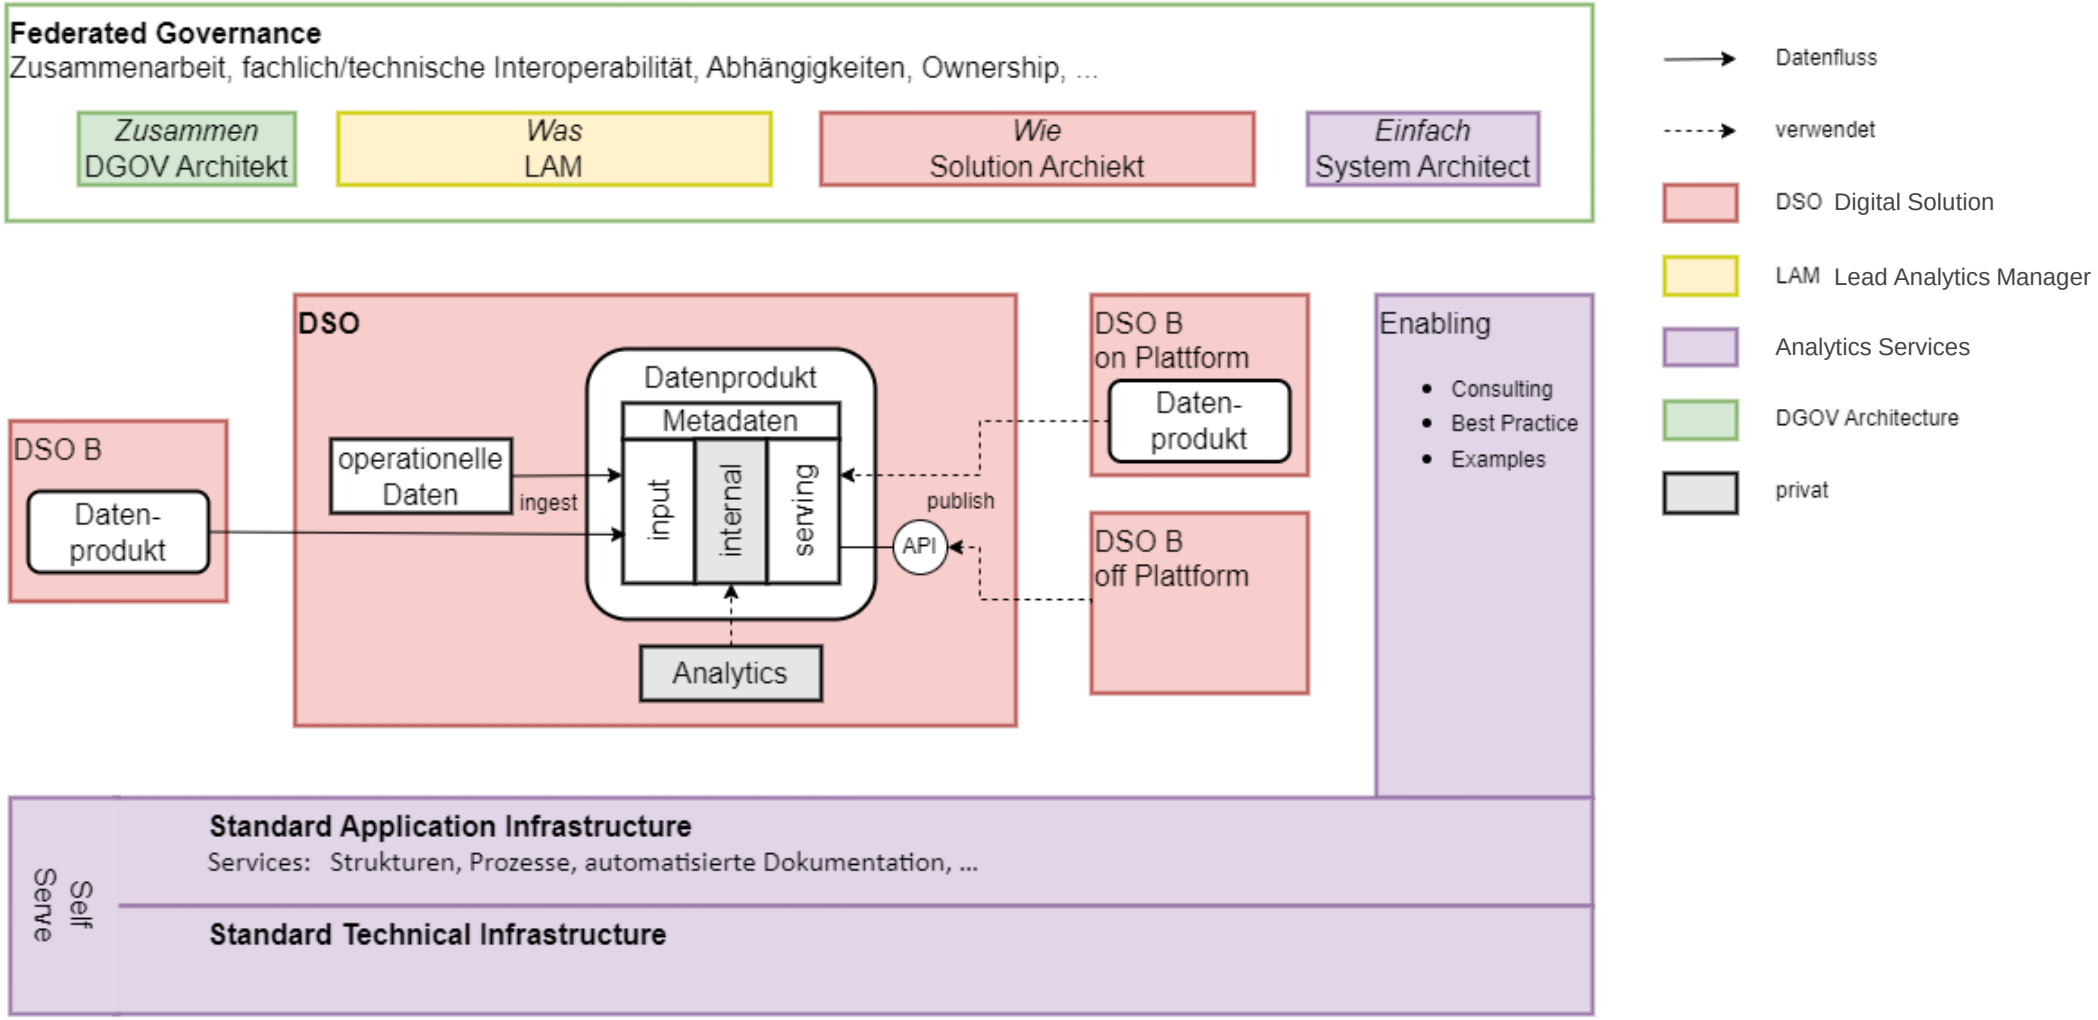

Angelehnt an: data-mesh.com

C2 – Internal

Herausforderungen

- Übernahme der Verantwortung für Data Products
  - Pflege der semantischen Metadaten
  - Bedarf an Data Products vs. Geschwindigkeit der Data Products-Erstellung vs. Qualitätsanforderungen
- Data Products und experimentelle Analytics-Nutzung
- Technisch noch kaum Standards und Plattformen (z.B. DP Market Places)
- Etablierung der Qualitätsmessung für Data Products (Monitoring, Usage, …)
- Grenze/Brücke von Data Products zu operationalen Daten

C2 – Internal

Beispiel: Technische Implementierung von Data Products über 2 technische Plattformen

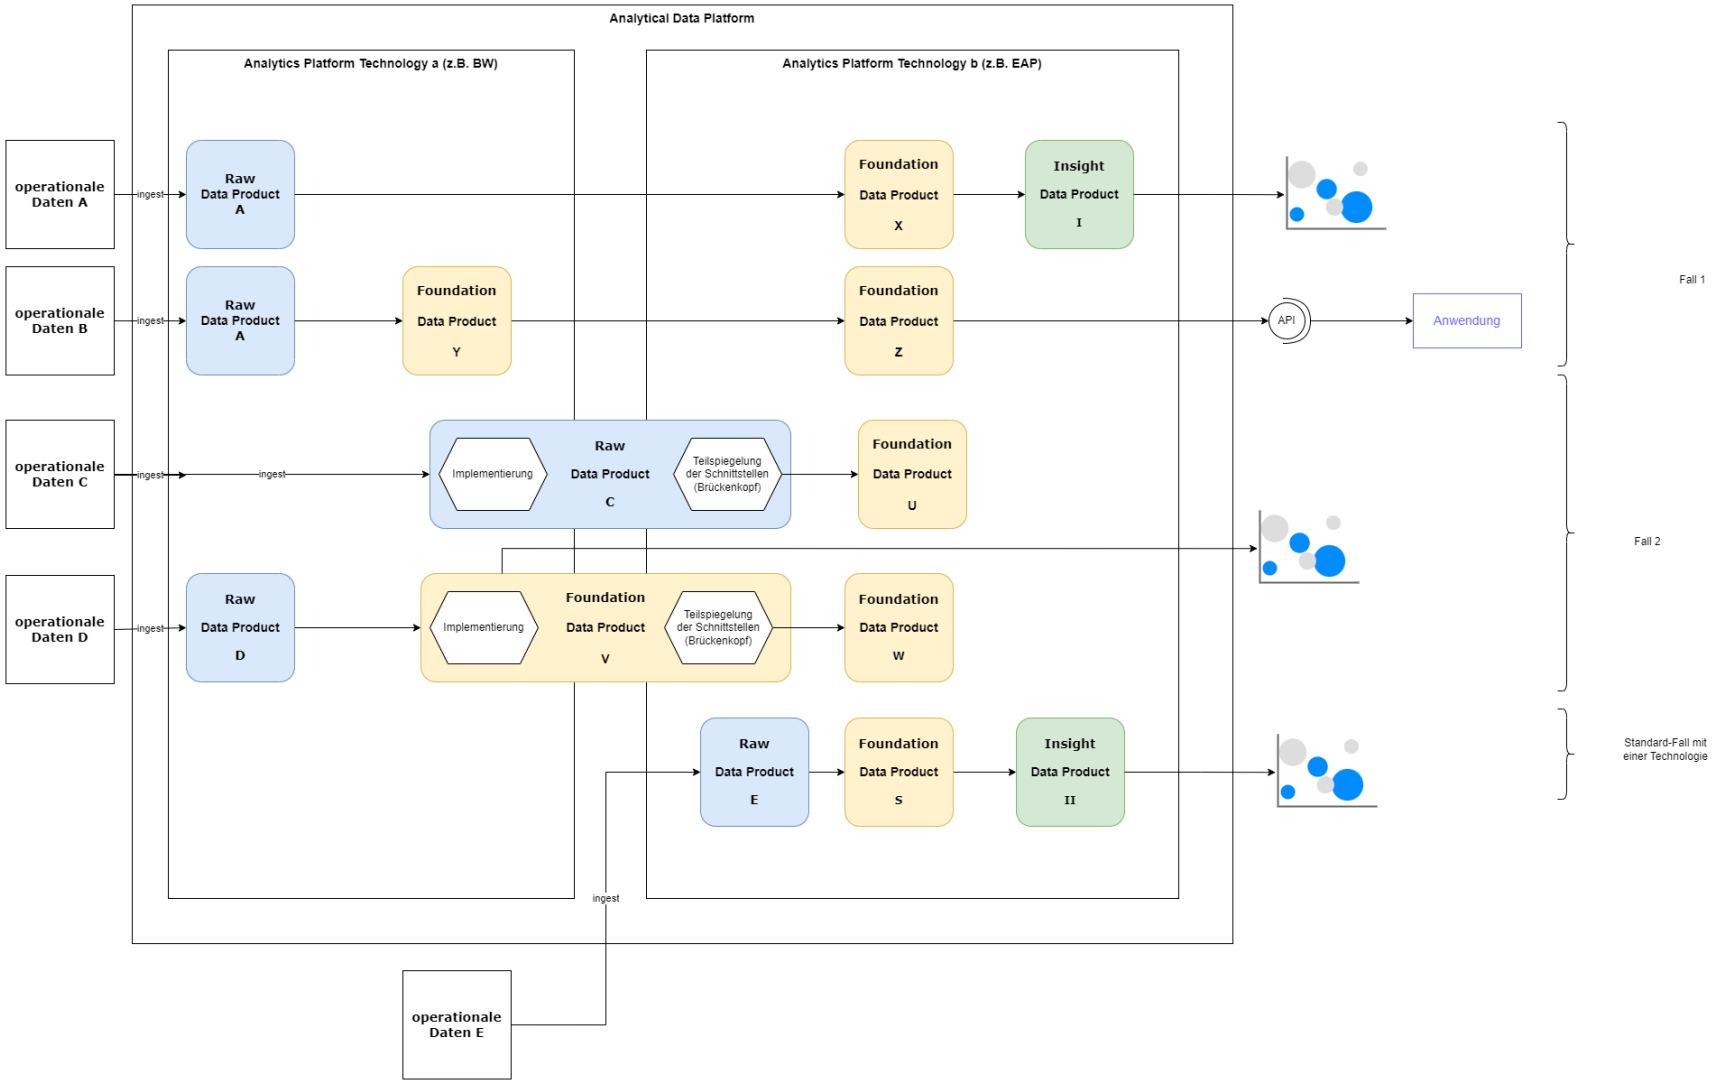

C2 – Internal

Ausblick

- Automatisierung und Standardisierung (evtl. in Richtung ODPS) steigern
- Zugang z.B. über internen DP-Marketplace noch einfacher machen
- Ausweitung des Konzeptes über die Analytical Data Platform hinaus

C2 – Internal

Eine etwas ausschweifende Definition aus unserm Wörterbuch
(… noch eine)

Ein Data Product ist ein IT-Komponente, welches dazu dient, Daten in **nutzerorientierter** Form für jegliche Datenkonsumentin bereitzustellen. Dazu bezieht es Daten aus Anwendungen oder anderen Data Products und transformiert diese in ein definiertes Format.

Ein Data Product besteht aus **Dateninhalt**, **Metadaten** sowie dem **Programmcode** zu deren Transformation und Bereitstellung. Die Bereitstellung erfolgt auf einer dafür vorgesehenen Plattform, der Zugriff über vordefinierte **Schnittstellen**.

Für ein Data Product ist immer eine verantwortliche Person festgelegt, die für deren Inhalte **verantwortlich** zeichnet.

C2 – Internal